FRESH GRADUATE ACADEMY

RMS Titanic Disaster

A woman's heart is a deep ocean of secrets

DIGITEAM

Jundan Nidaaulhaq

Rizki Teguh Kurniawan

Wildan Hidayat

Latar Belakang

Peristiwa Titanic (15 April 1912) merupakan salah satu kecelakaan terbesar dalam sejarah di mana **dari 2224 penumpang hanya 707 yang selamat** (Frey, et al. 2010). Kapal Titanic menabrak bongkahan es saat melakukan perjalanan dari Southampton ke New York. Kapal Titanic karam dalam waktu 2 jam 40 menit sejak peristiwa tersebut. Waktu tersebut dinilai cukup untuk memunculkan karakteristik sikap manusia sebagai mahluk sosial dalam menghadapi situasi darurat (Frey, et al. 2010).

TUJUAN

- MELIHAT HUBUNGAN ANTAR ATRIBUT YANG DAPAT MENJELASKAN TINDAKAN APA YANG DILAKUKAN PENUMPANG TITANIC UNTUK BERTAHAN HIDUP
- MELIHAT SEBERAPA AKURAT ATRIBUT-ATRIBUT PADA DATA MEMPREDIKSI KEMUNGKINAN MANUSIA UNTUK BERTAHAN HIDUP

DATA

- 1309 BARIS
  15 KOLOM

pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked	boat	body	home.dest
1	1	Allen, Miss. Elisabeth Walton	female	29	0	0	24160	211.3375	B5	S	2		St Louis, MO
1	1	Allison, Master. Hudson Trevor	male	0.917	1	2	113781	151.5500	C22 C26	S	11		Montreal, PQ / Chesterville, ON
1	0	Allison, Miss. Helen Loraine	female	2	1	2	113781	151.5500	C22 C26	S			Montreal, PQ / Chesterville, ON
1	0	Allison, Mr. Hudson Joshua Creighton	male	30	1	2	113781	151.5500	C22 C26	S		135	Montreal, PQ / Chesterville, ON
1	0	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	female	25	1	2	113781	151.5500	C22 C26	S			Montreal, PQ / Chesterville, ON
1	1	Anderson, Mr. Harry	male	48	0	0	19952	26.5500	E12	S	3		New York, NY
1	1	Andrews, Miss. Kornelia Theodosia	female	63	1	0	13502	77.9583	D7	S	10		Hudson, NY
1	0	Andrews, Mr. Thomas Jr	male	39	0	0	112050	0.0000	A36	S			Belfast, NI
1	1	Appleton, Mrs. Edward Dale (Charlotte Lamson)	female	53	2	0	11769	51.4792	C101	S	D		Bayside, Queens, NY
1	0	Artagaveytia, Mr. Ramon	male	71	0	0	PC 17609	49.5042		C		22	Montevideo, Uruguay
1	0	Astor, Col. John Jacob	male	47	1	0	PC 17757	227.5250	C62 C64	C		124	New York, NY
1	1	Astor, Mrs. John Jacob (Madeleine Talmadge Force)	female	18	1	0	PC 17757	227.5250	C62 C64	C	4		New York, NY
1	1	Aubart, Mme. Leontine Pauline	female	24	0	0	PC 17477	69.3000	B35	C	9		Paris, France
1	1	Barber, Miss. Ellen "Nellie"	female	26	0	0	19877	78.8500		S	6		
1	1	Barkworth, Mr. Algernon Henry Wilson	male	80	0	0	27042	30.0000	A23	S	B		Hessle, Yorks
1	0	Baumann, Mr. John D	male		0	0	PC 17318	25.9250		S			New York, NY
1	0	Baxter, Mr. Quigg Edmond	male	24	0	1	PC 17558	247.5208	B58 B60	C			Montreal, PQ
1	1	Baxter, Mrs. James (Helene DeLaudeniere Chaput)	female	50	0	1	PC 17558	247.5208	B58 B60	C	6		Montreal, PQ
1	1	Bazzani, Miss. Albina	female	32	0	0	11813	76.2917	D15	C	8		
1	0	Beattie, Mr. Thomson	male	36	0	0	13050	75.2417	C6	C	A		Winnipeg, MN
1	1	Beckwith, Mr. Richard Leonard	male	37	1	1	11751	52.5542	D35	S	5		New York, NY

METODE

UNDERSTANDING

Studi literatur dan Exploratory Data Analysis

PREPARATION

Pemberishan data dari noisy data, missing values, incorrect data types, outliers, dan imbalanced dataset dan pengurangan atribut yang tidak relevan

PREDICTION

Pembentukan model dengan beberapa algoritma klasifikasi seperti SVC, Random Forest, Decision Tree, dan Logistic Regression

EVALUATION

Mengevaluasi model dari nilai accuracy, precision, dan recall. Selanjutnya melakukan parameter tuning pada model.

Data Understanding

Data Type

```
1  df.dtypes
```

```
pclass        int64
survived      int64
name         object
sex          object
age         float64
sibsp         int64
parch         int64
ticket       object
fare        float64
cabin        object
embarked     object
boat         object
body        float64
home.dest    object
dtype: object
```

Missing Values and Data Balance

```
pclass          0
survived        0
name            0
sex             0
age           263
sibsp           0
parch           0
ticket          0
fare            1
cabin        1014
embarked        2
boat          823
body         1188
home.dest     564
dtype: int64
```

Survive : 500

Not Survive : 809

Attribute Correlation

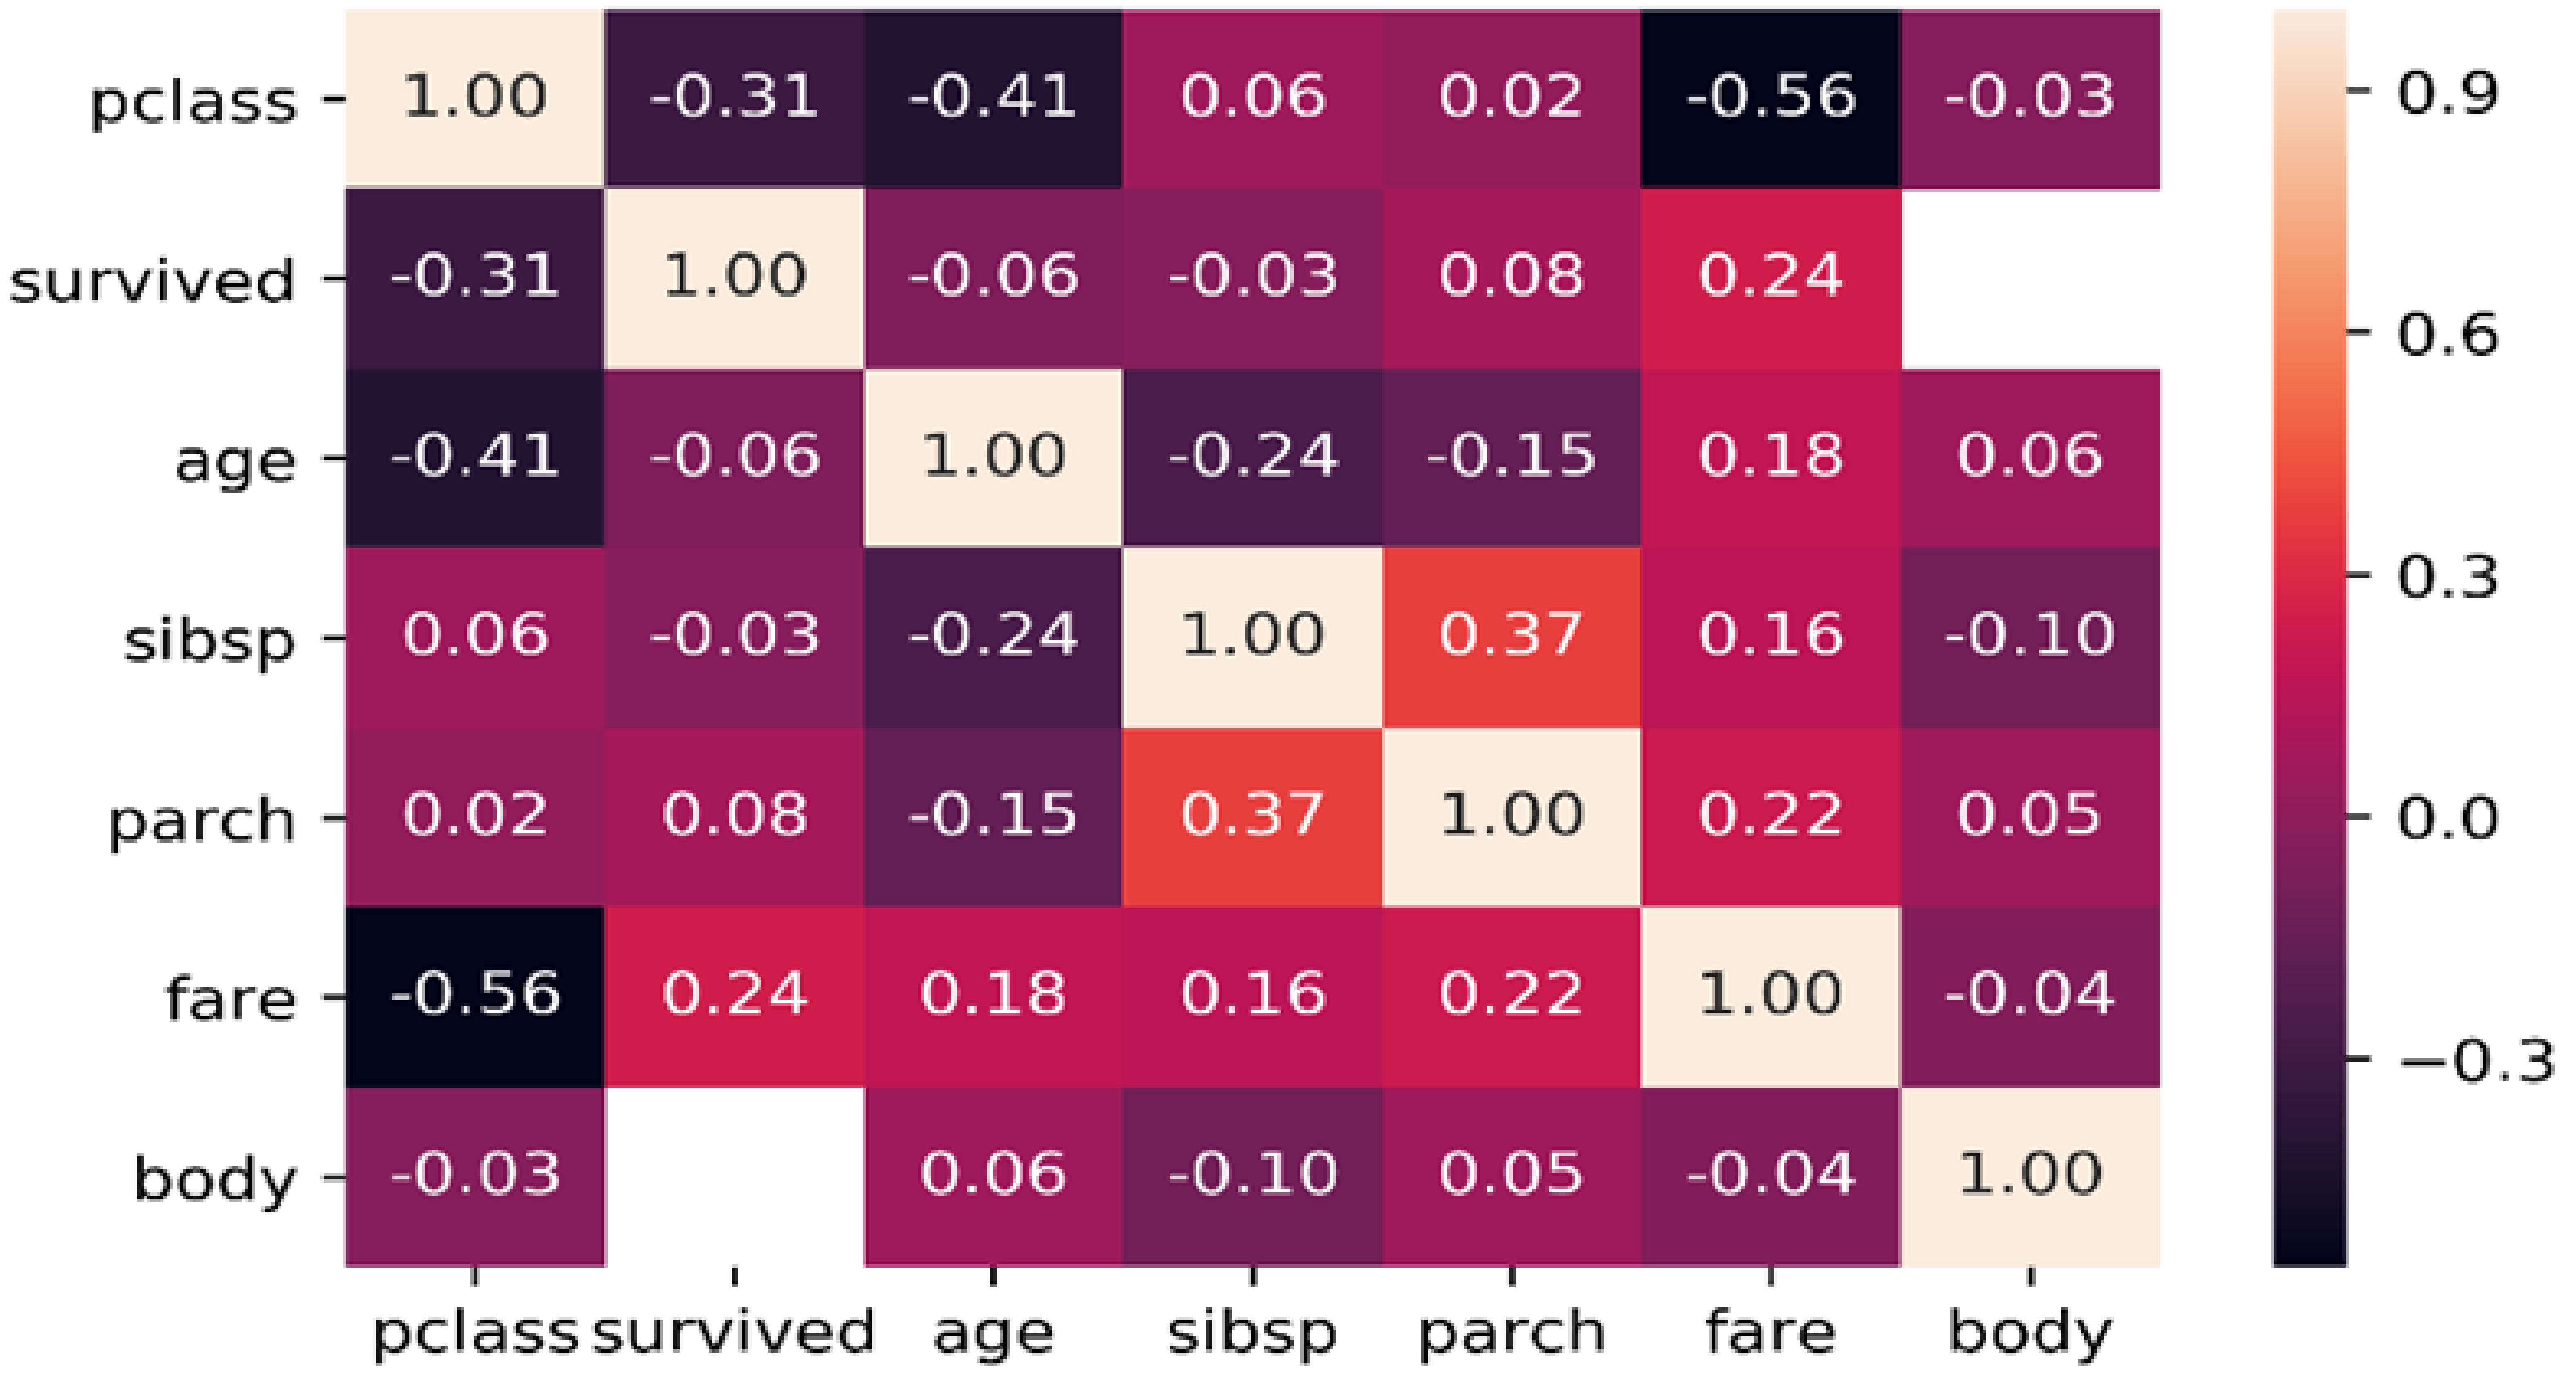

Attribute Outliers

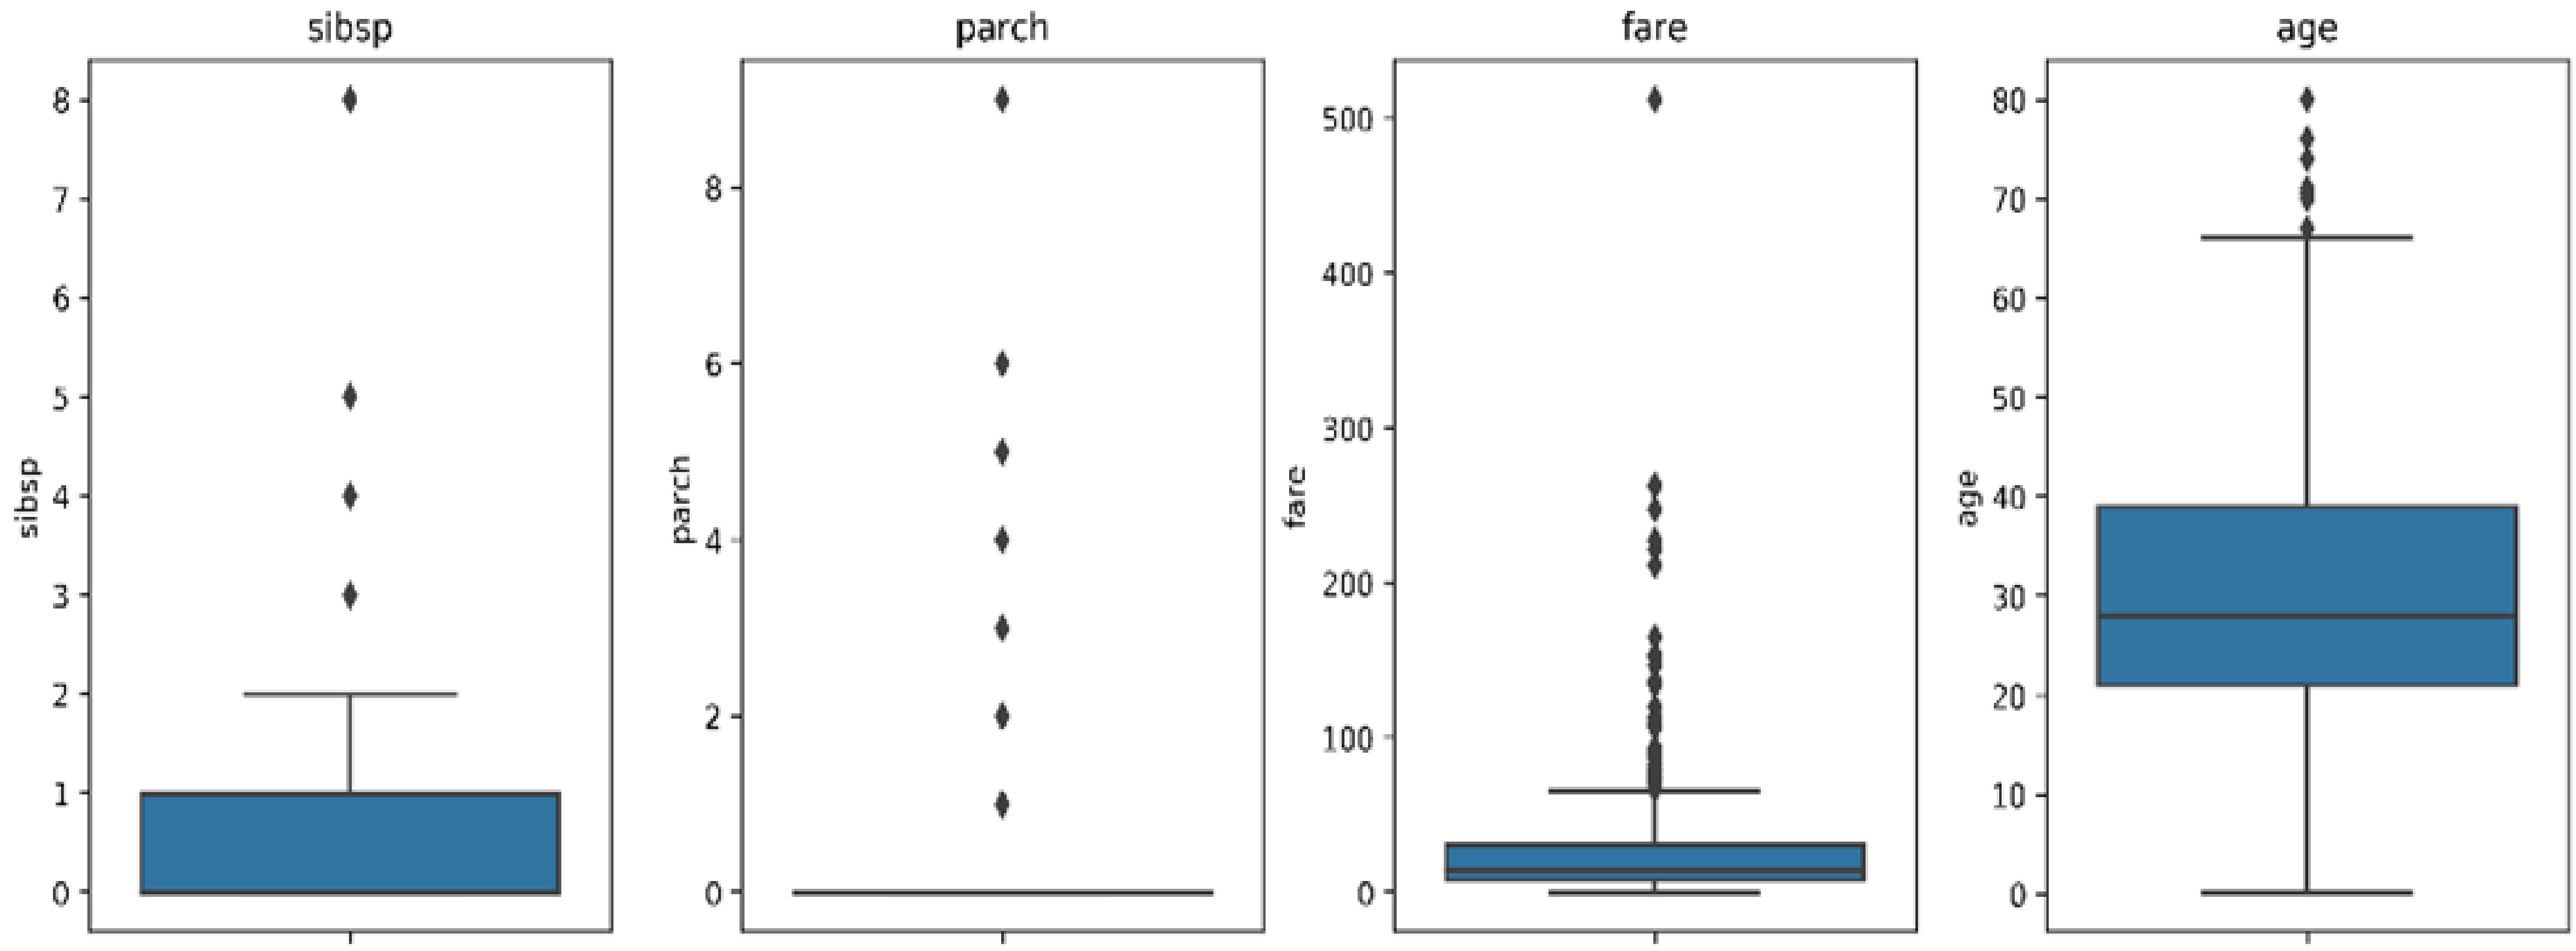

Attribute-Survive Correlation

Gambar 4. Hubungan antara data *sex*, *age* dan *survived*

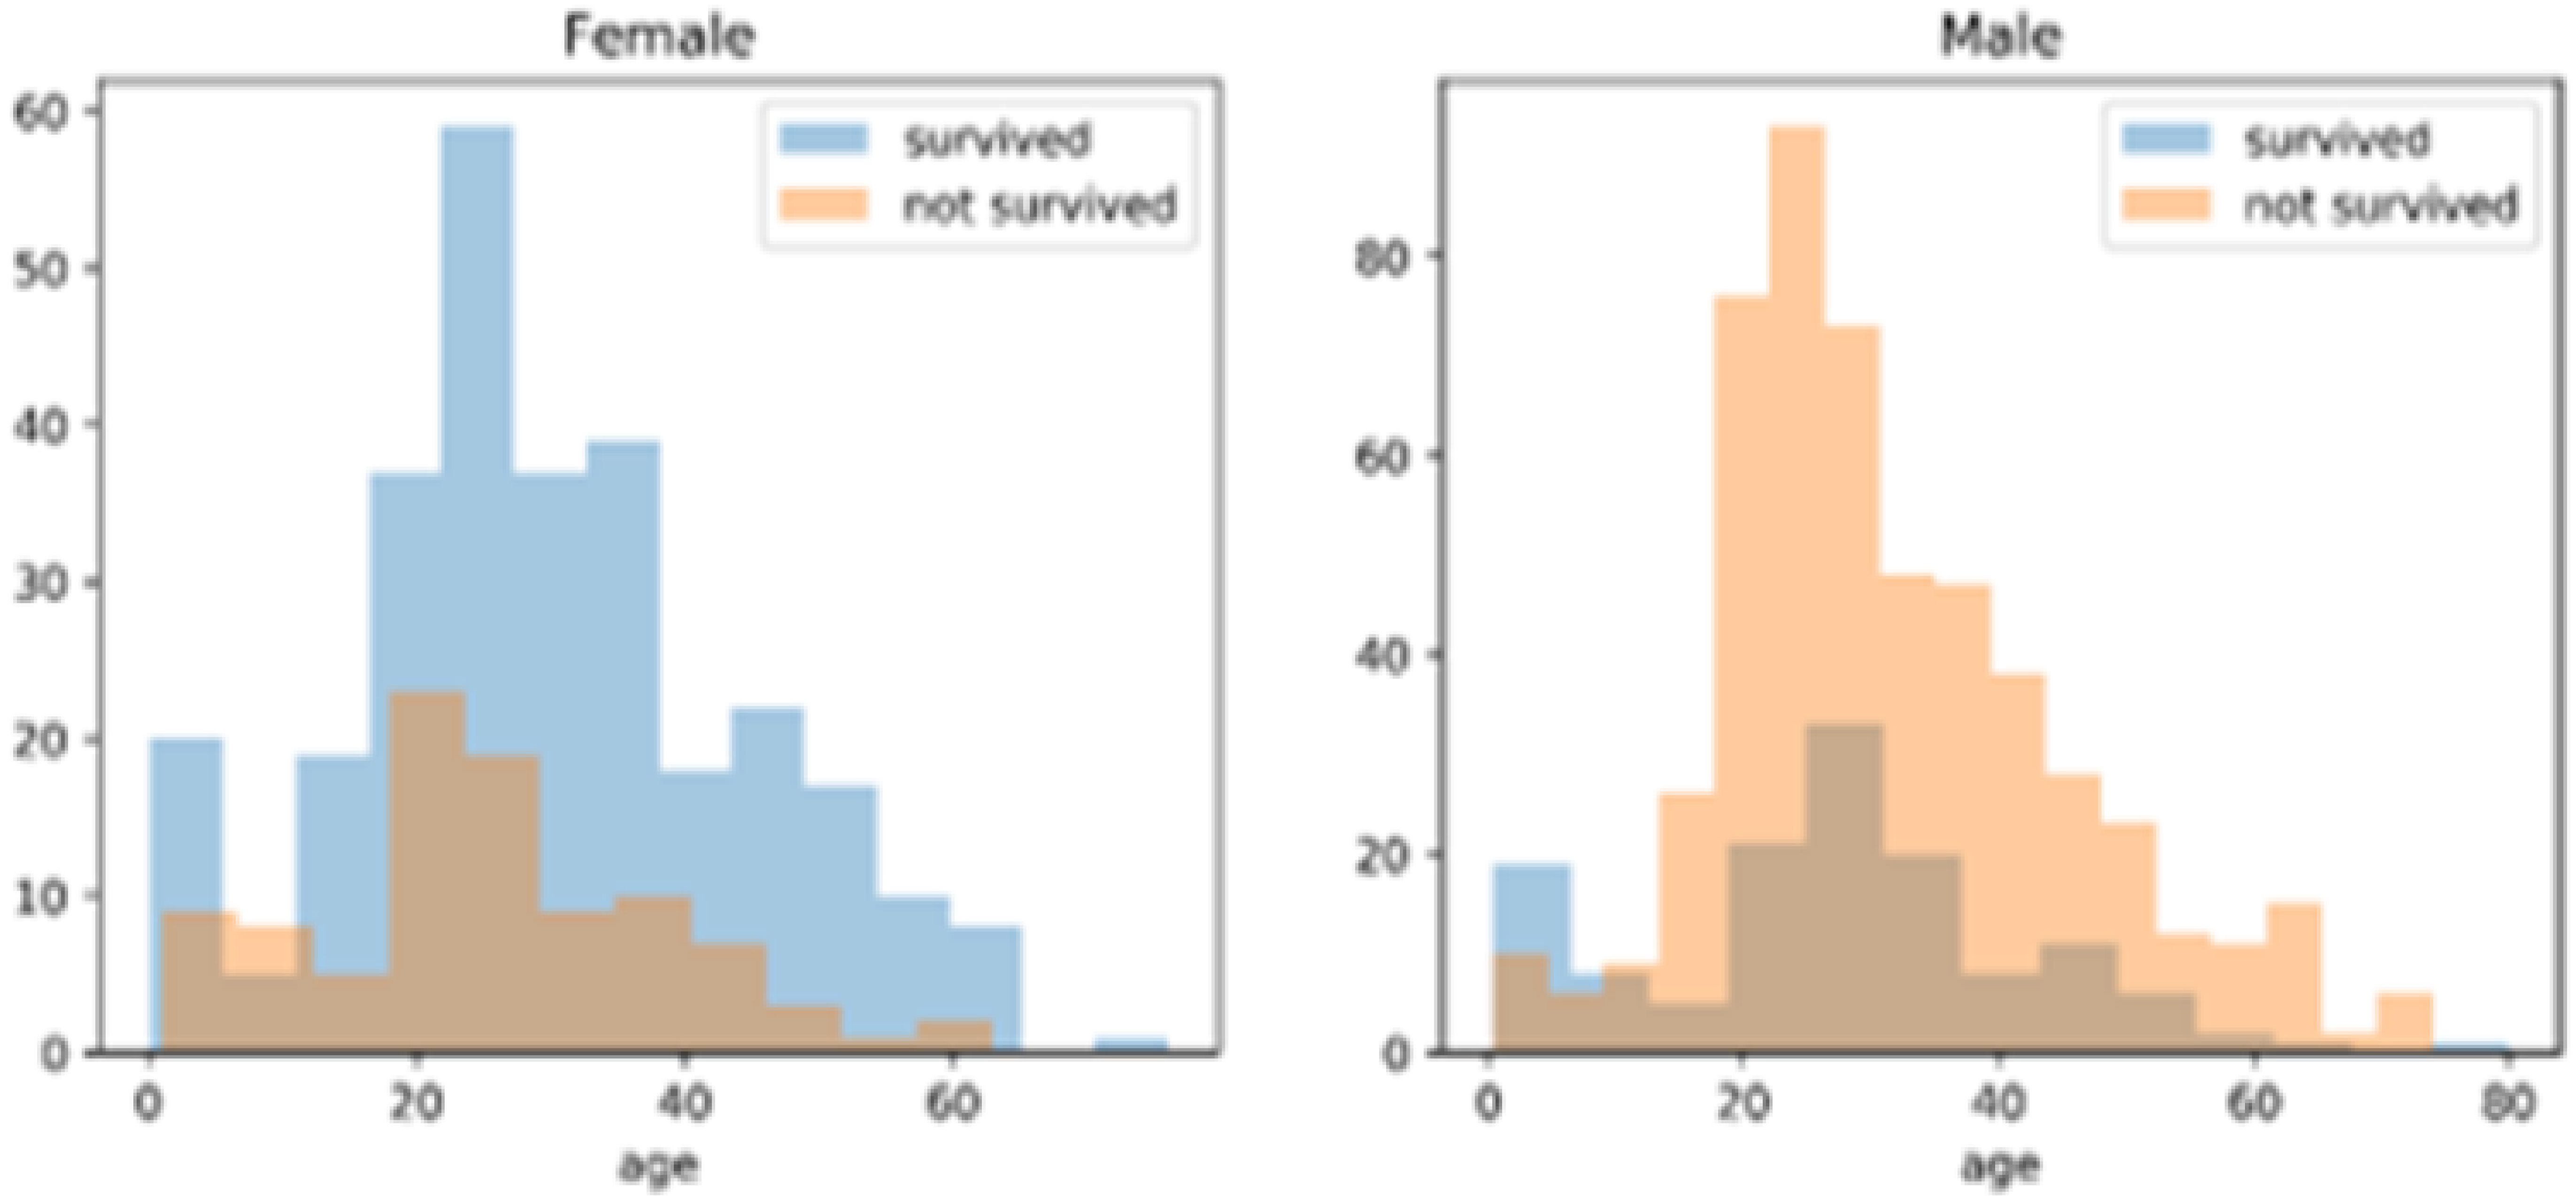

Attribute-Survive Correlation

Gambar 5. Hubungan antara kemungkinan bertahan hidup dengan usia

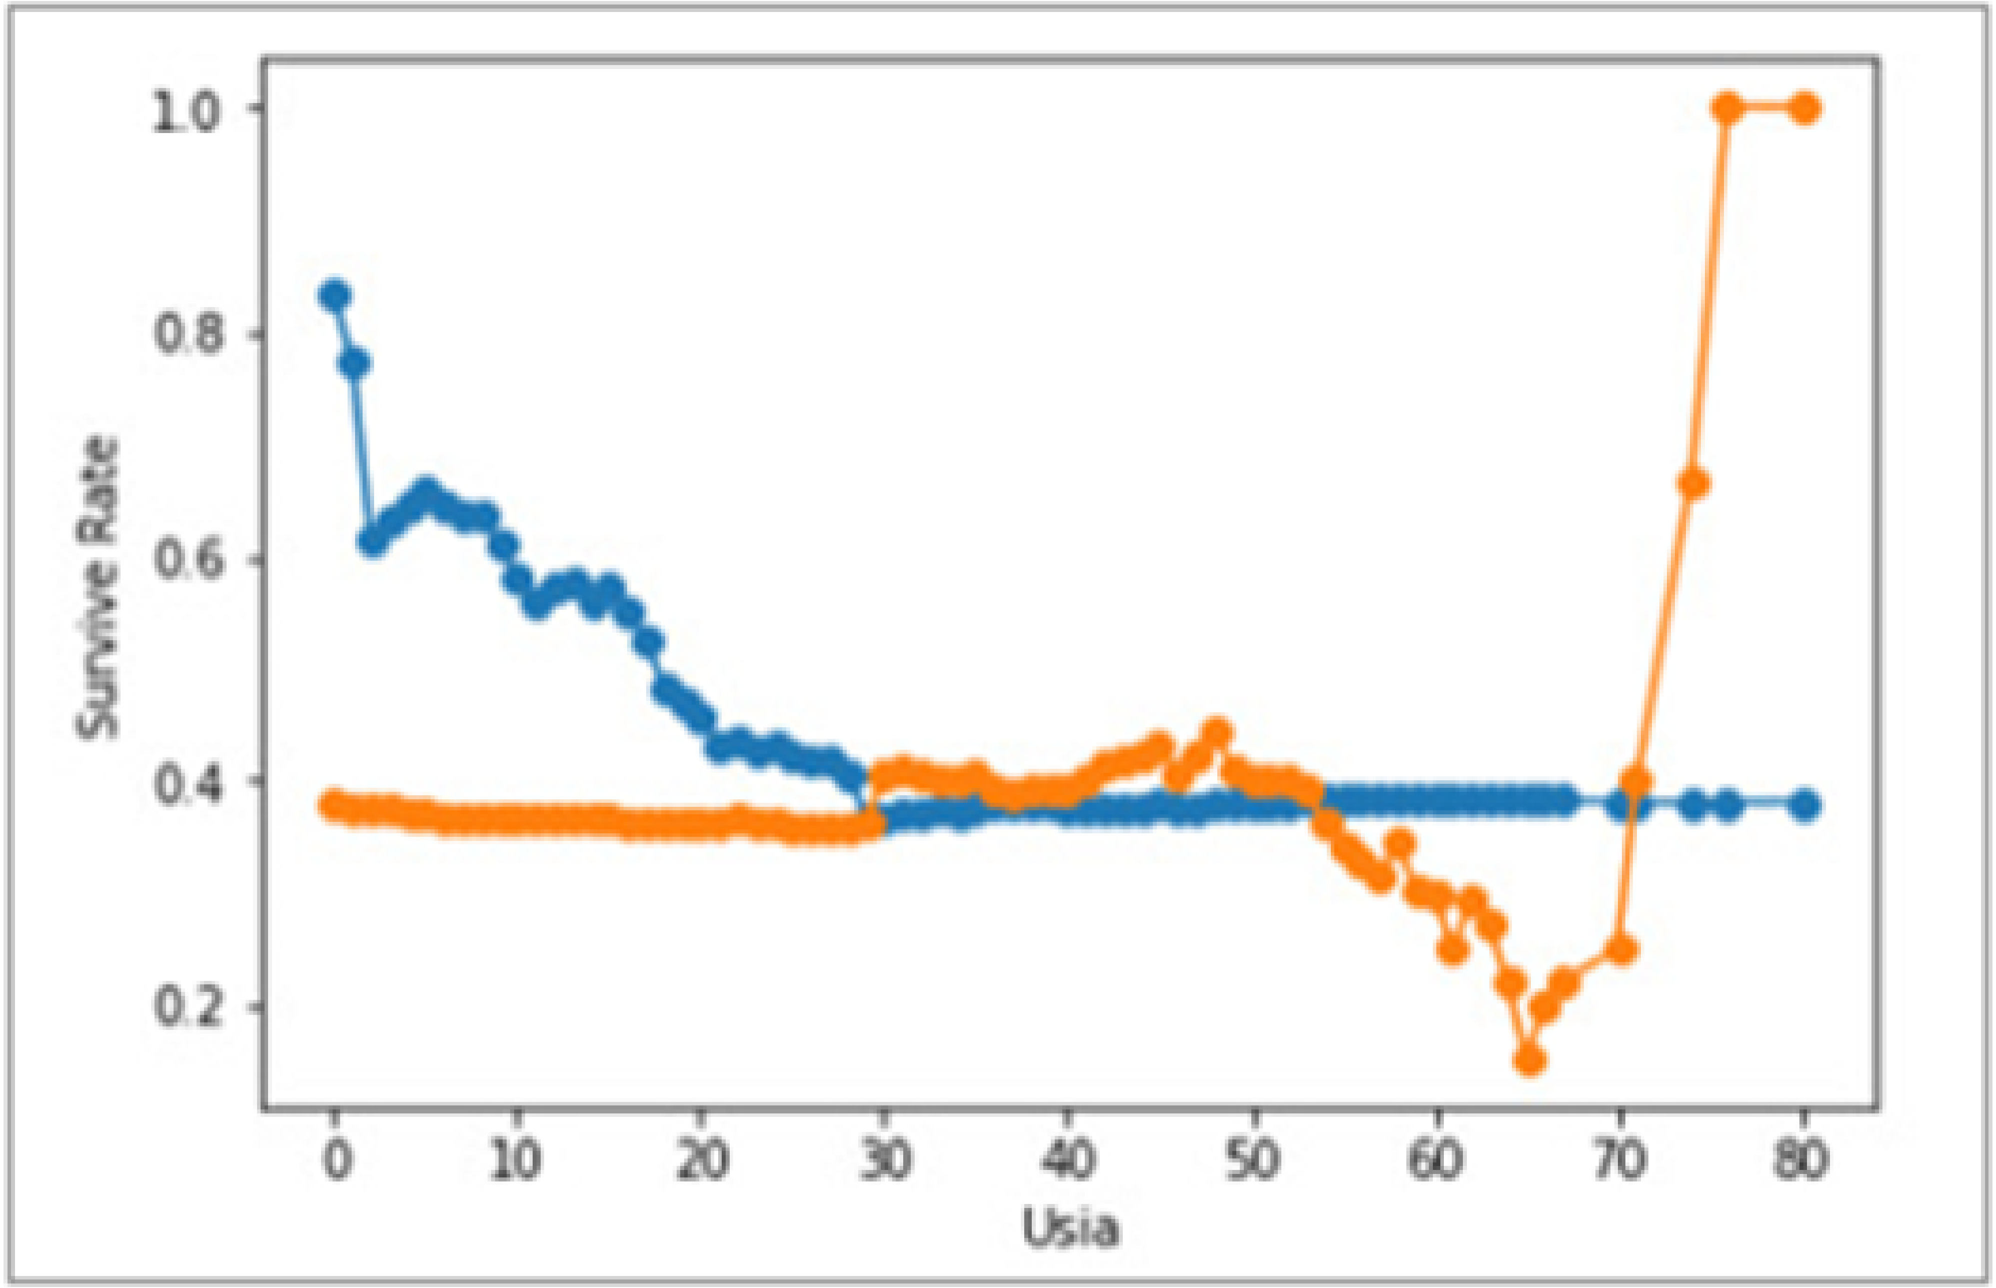

Attribute-Survive Correlation

Gambar 6. Hubungan antara data *class*, *age* dan *survived*

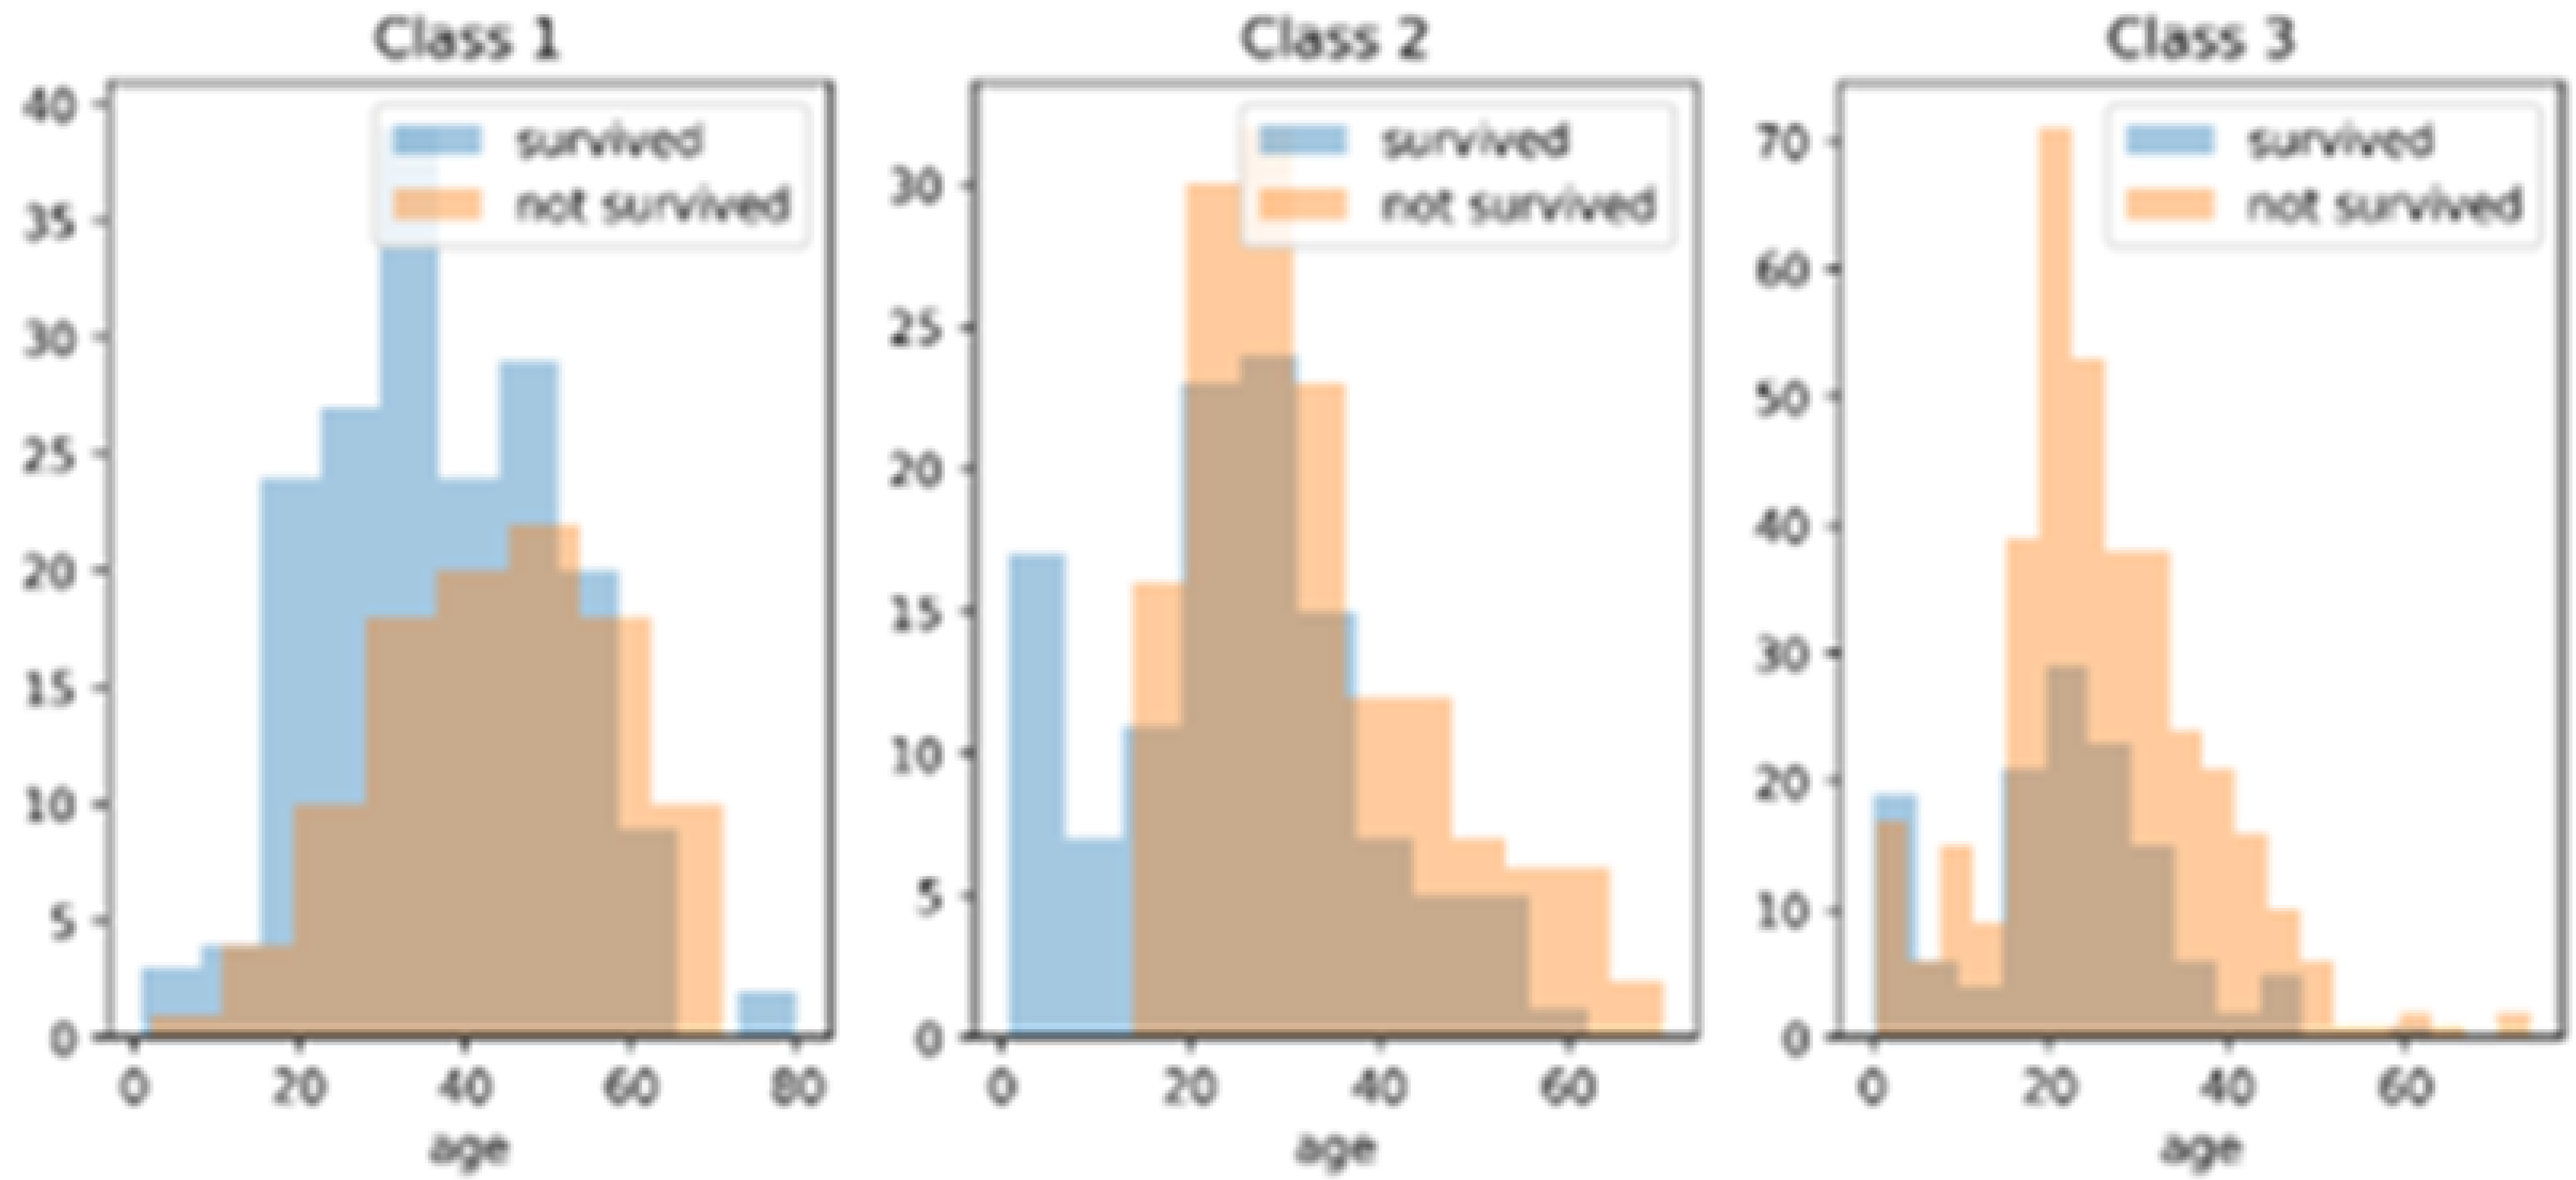

Attribute-Survive Correlation

Gambar 7. Hubungan antara data *class*, *sex* dan *survived*

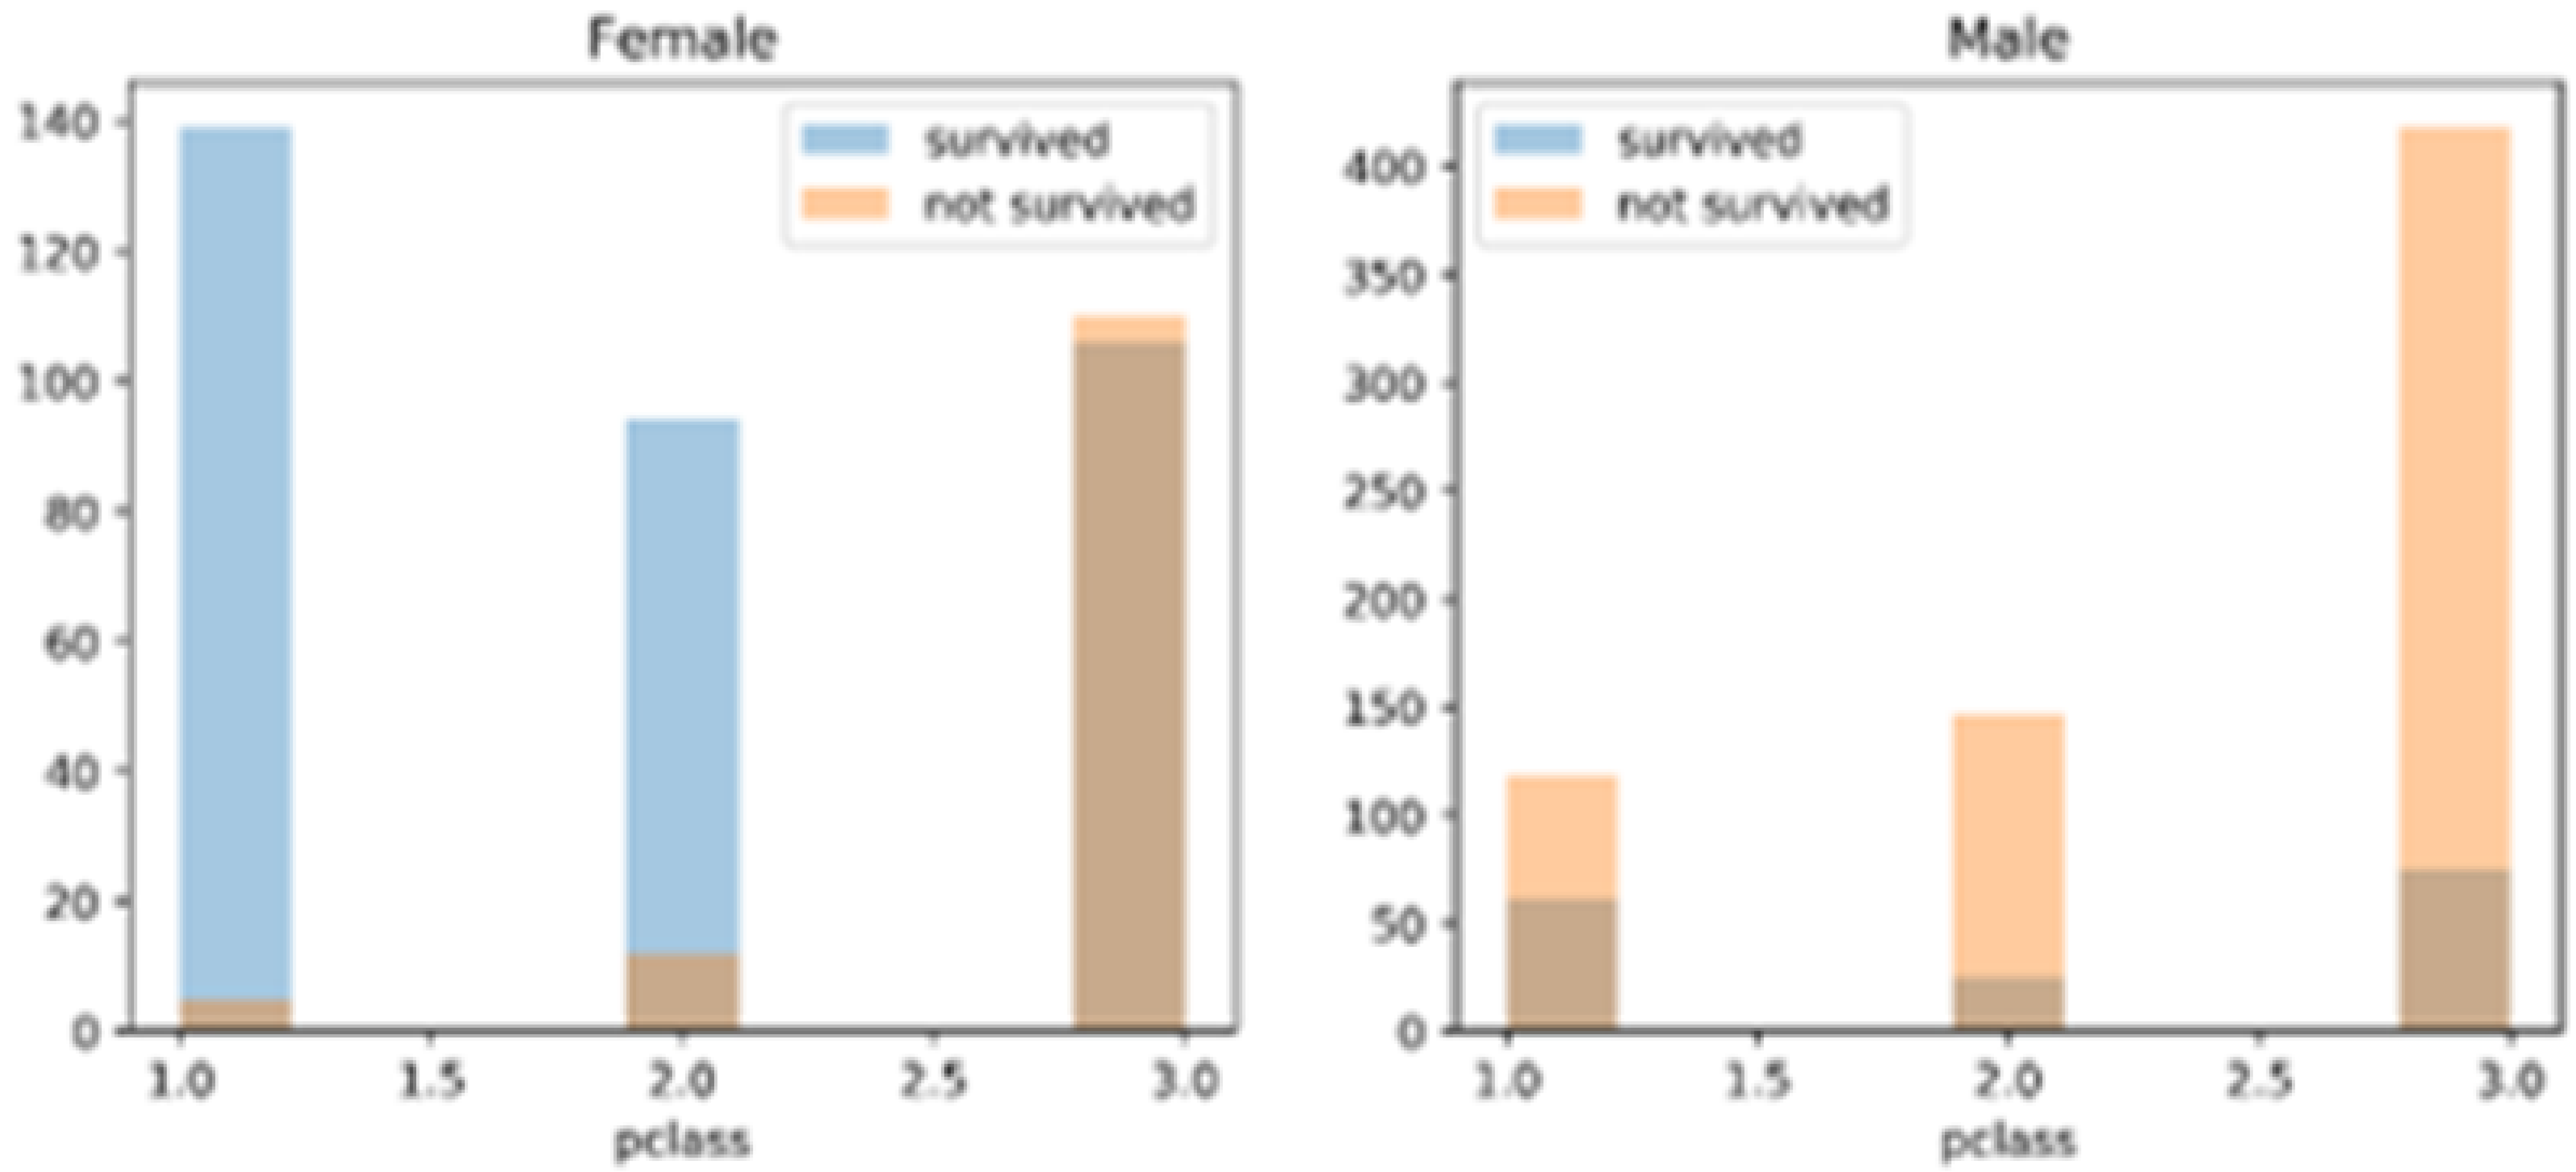

Attribute-Survive Correlation

Gambar 8. Hubungan antara data *fare*, *sex* dan *survived*

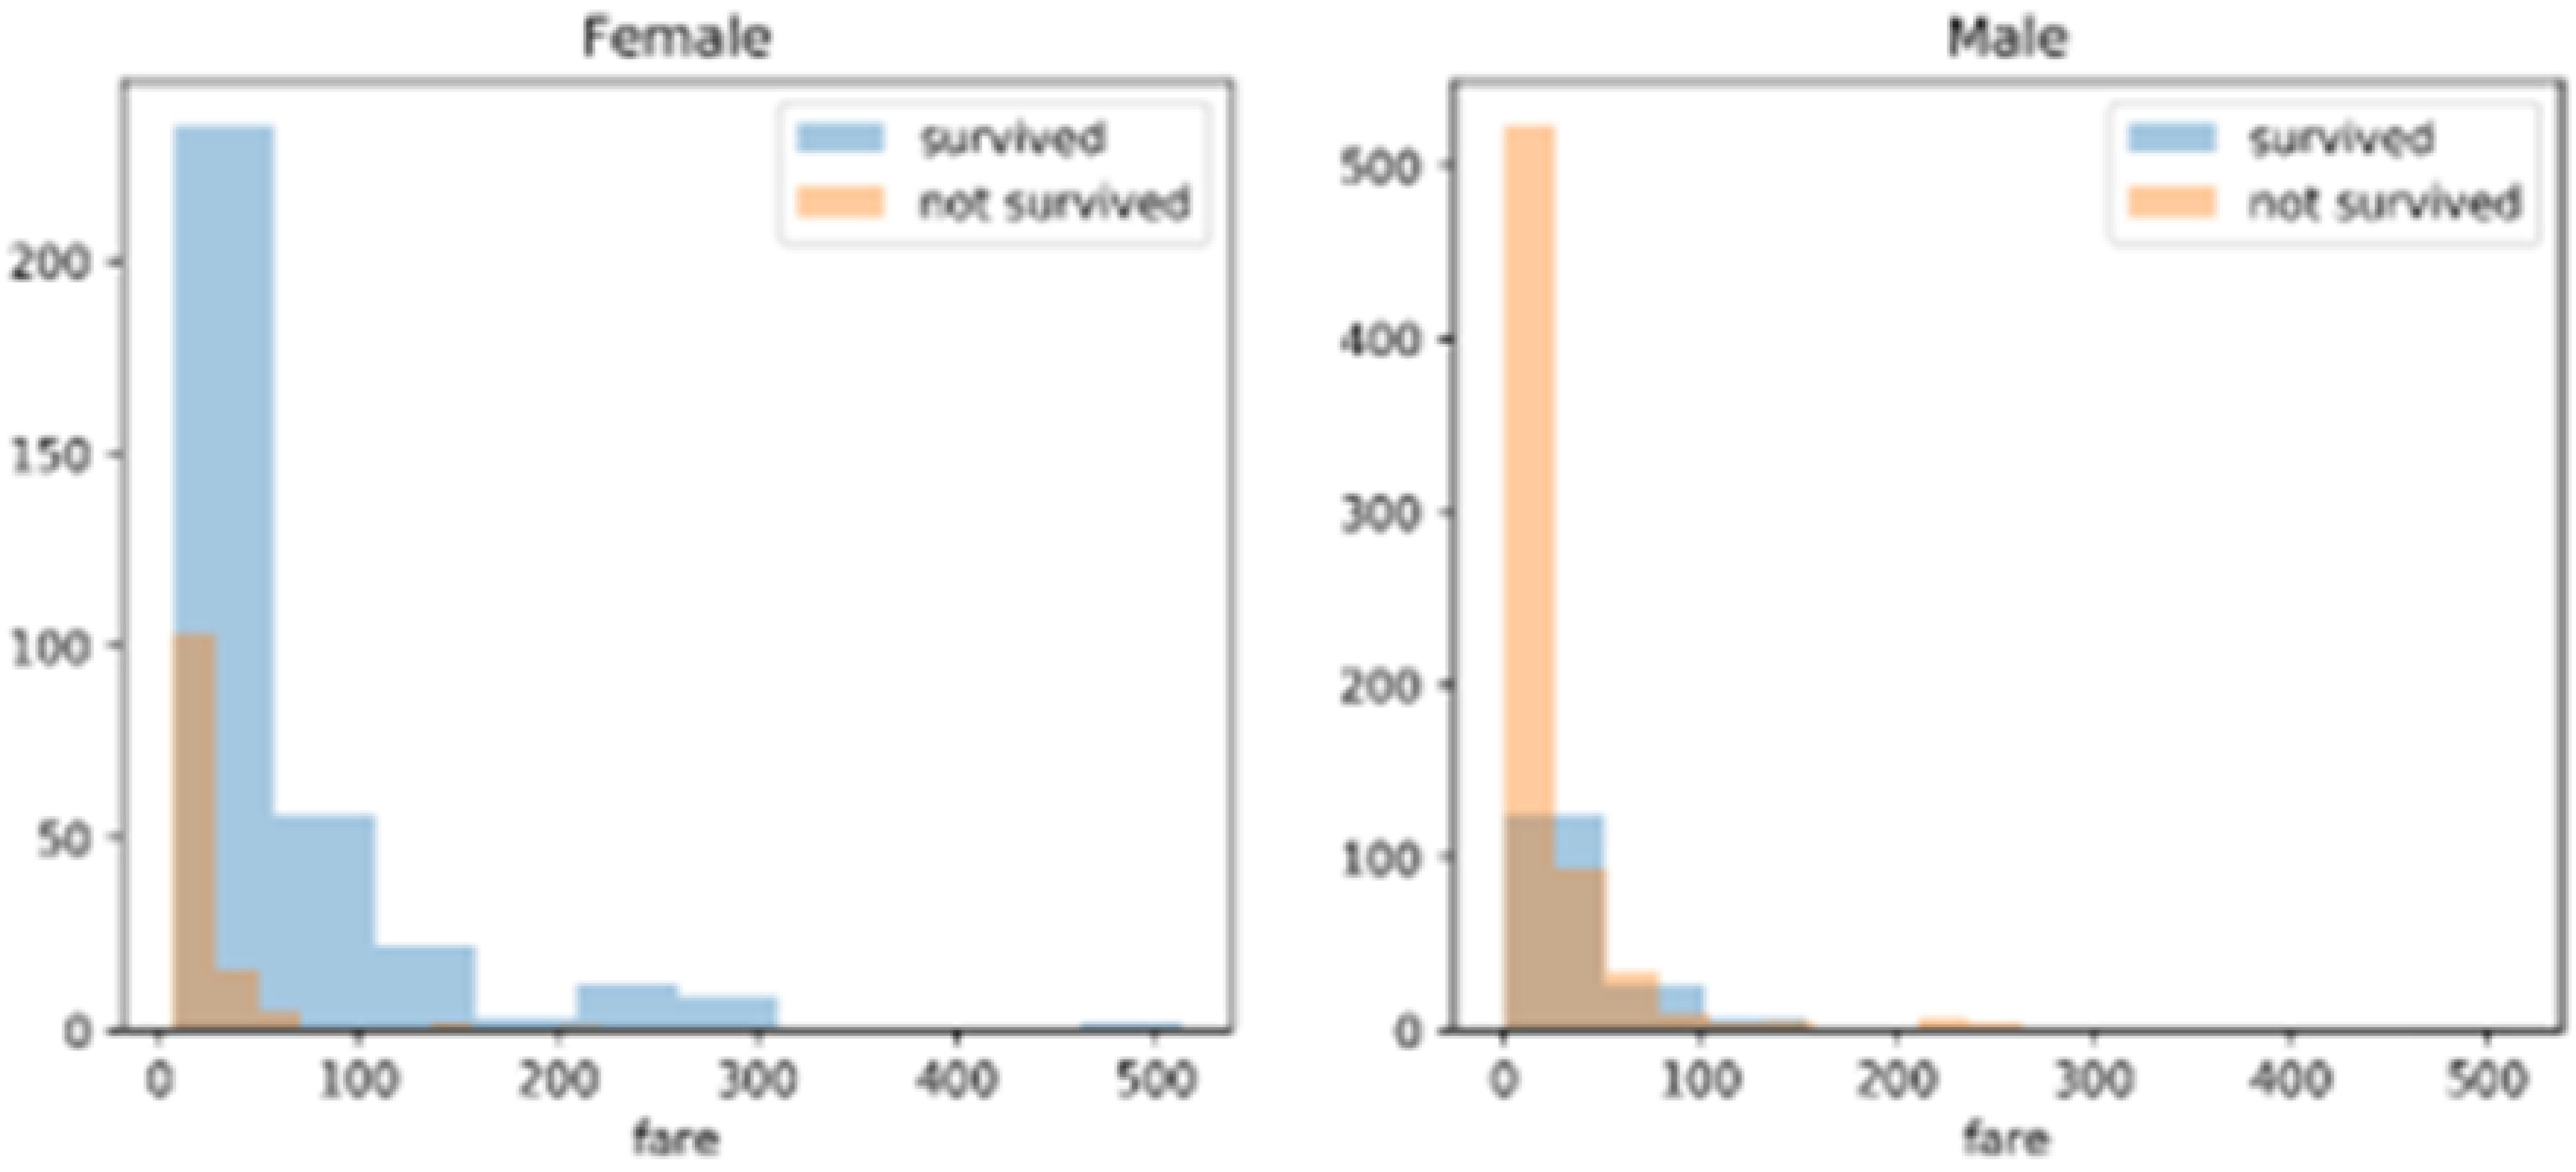

Attribute-Survive Correlation

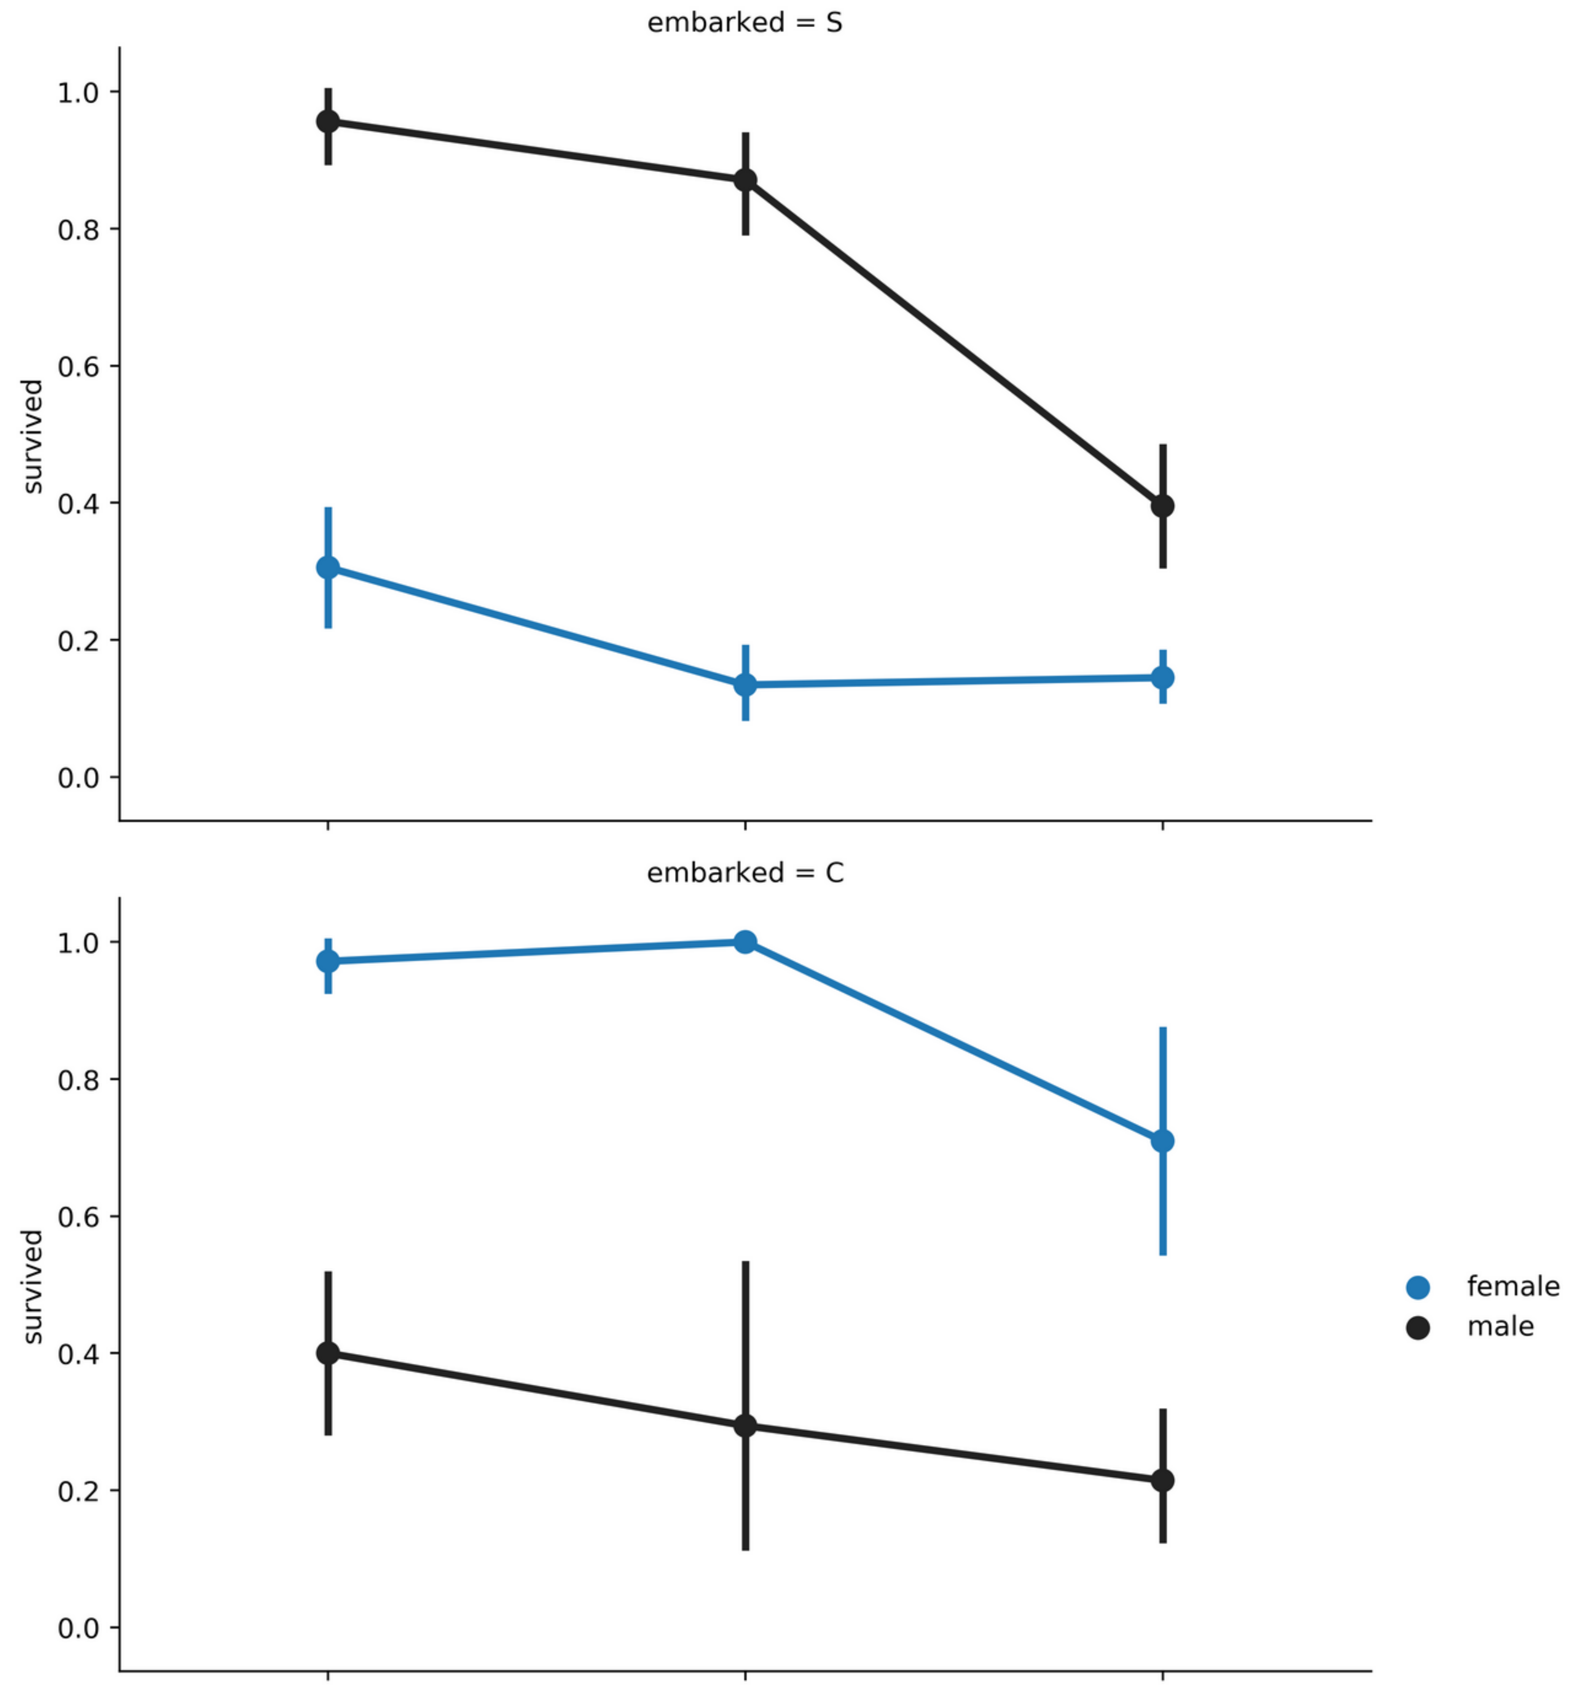

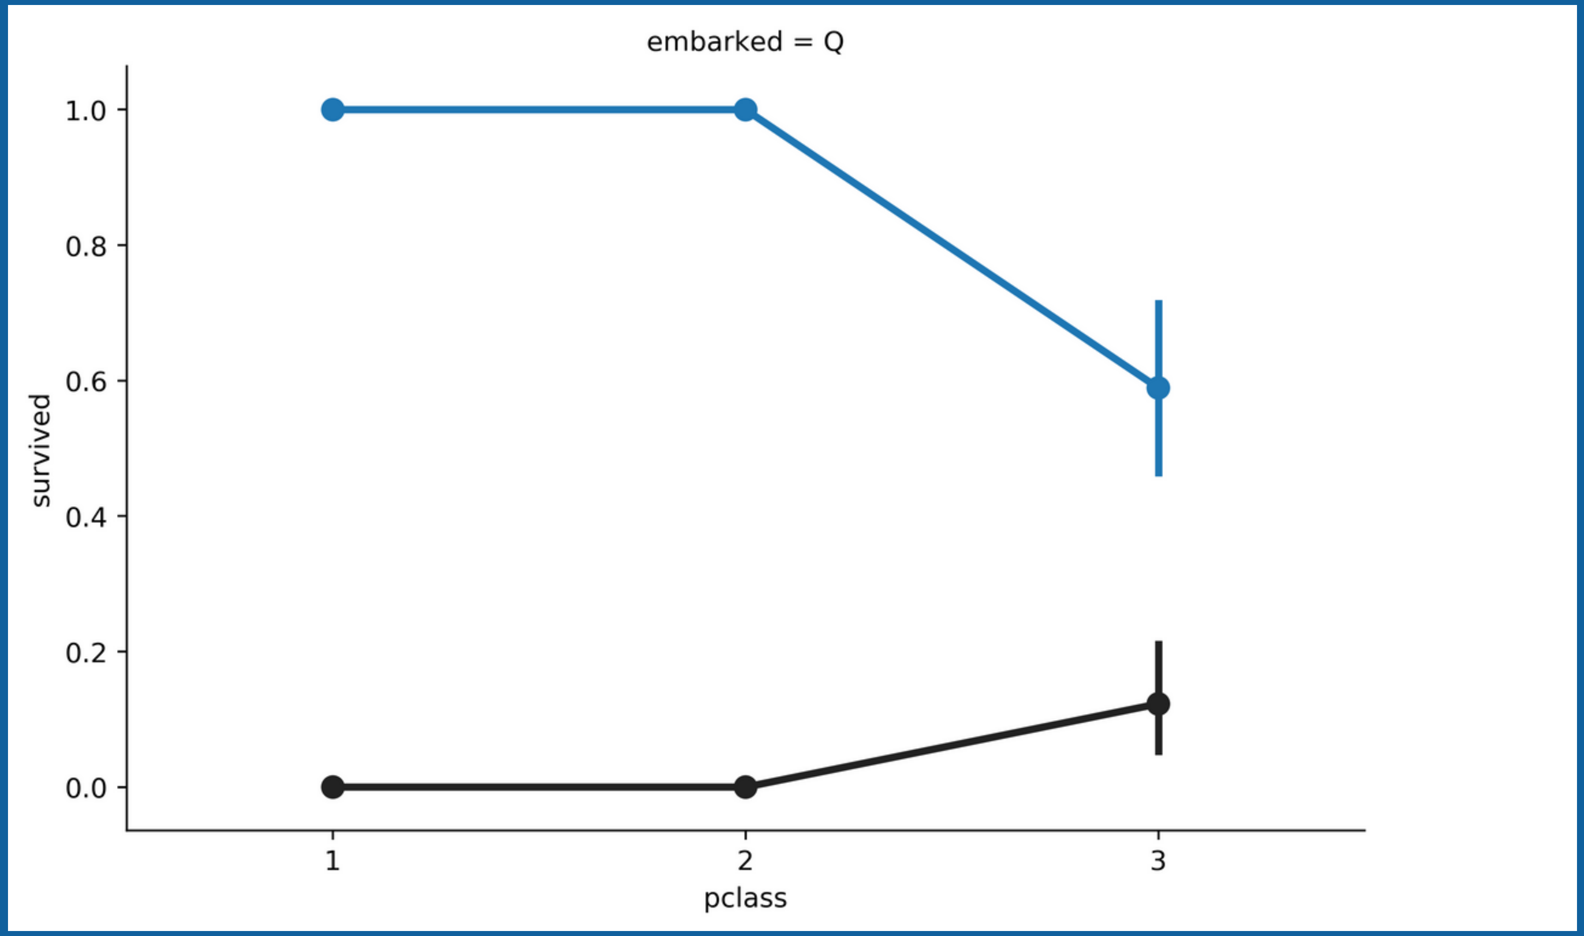

Attribute-Survive Correlation

Honor/ Titile Attribute

```
Survive rate of  honor/Title  Attribute :
Lady       : from  1      survive  1      Rate :  1.0000
Mme        : from  1      survive  1      Rate :  1.0000
Mlle       : from  2      survive  2      Rate :  1.0000
the Countess  : from  1   survive  1      Rate :  1.0000
Dona       : from  1      survive  1      Rate :  1.0000
Sir        : from  1      survive  1      Rate :  1.0000
Don        : from  1      survive  0      Rate :  0.0000
Major      : from  2      survive  1      Rate :  0.5000
Ms         : from  2      survive  1      Rate :  0.5000
Col        : from  4      survive  2      Rate :  0.5000
Dr         : from  8      survive  4      Rate :  0.5000
Rev        : from  8      survive  0      Rate :  0.0000
Capt       : from  1      survive  0      Rate :  0.0000
Jonkheer    : from  1     survive  0      Rate :  0.0000

Mrs        : from  197    survive  155    Rate :  0.7868
Miss       : from  260    survive  176    Rate :  0.6769
Master     : from  61     survive  31     Rate :  0.5082
Mr         : from  757    survive  123    Rate :  0.1625
```

Data Preparation

- Drop atribut ticket, cabin, body,
- Atribut name diisi dengan title dari penumpang seperti Mr. Mrs. Master. dan lain-lain selanjutnya digunakan Label Encoder
- Atribut sex diubah menjadi numerik (Female = 1, Male =0)
- Atribut age diubah menjadi categorical seperti children, youth, adult, dan senior.
- Missing value pada atribut fare diisi berdasarkan nilai kuartil dan dikategorisasi menjadi cheap, normal, high, expensive.
- Menambahkan atribut Mother, Children, Alone, Priority, dan Respectable

HASIL

No	Algoritma Pembelajaran Mesin	A (%)	Std (%)	A.os (%)	Std.os (%)
1	*Logistic Regression*	81.24	2.95	79.68	2.54
2	*Support Vector Machine*	81.74	3.03	80.16	2.59
3	*Decision Tree*	78.86	3.12	78.38	3.11
4	*Random Forest*	79.20	3.12	79.55	3.16

•Algoritma Support Vector Machine (SVM) memberikan nilai akurasi paling baik.

•Lam et al. 2012, nilai akurasi dari SVM lebih tinggi 2.17% sedangkan hasil dari Decision Tree lebih rendah 1.05%. Namun hal tersebut masih berada pada rentang standar deviasi dari pemodelan.

•Kakde et al. 2018, rata-rata akurasi dari keempat algoritma pembelajaran yang sama sebesar 82.325%, lebih tinggi dari penelitian ini sebesar 79.44%.

•Singh et al. 2017 yang menunjukan performa rata-rata model lebih dari 90%.

No	Algoritma Pembelajaran Mesin	A (%)	Std (%)	A.os (%)	Std.os (%)
1	*Logistic Regression*	81.24	2.95	79.68	2.54
2	*Support Vector Machine*	81.74	3.03	80.16	2.59
3	*Decision Tree*	78.86	3.12	78.38	3.11
4	*Random Forest*	79.20	3.12	79.55	3.16

•Perbedaan pada proses features engineering. Perubahan data nominal kedalam data numerik berdasarkan pengelompokan yang mengacu pada aturan tertentu. Contoh: pengelompokan title penumpang berdasarkan nilai survival rate serta pengelompokan usia penumpang yang mengacu kepada definisi Statistics Canada.

•Hasil pemodelan menunjukan peningkatan nilai untuk data yang tidak diproses over sampling. Proses ini juga tidak ditemukan pada paper Kakde et al. 2018.

No	Parameter	Nilai	Nilai.os
1	C	10	50
2	Gamma	0.01	0.01
3	Kernel	rbf	rbf
4	Akurasi (%)	81.49	80.29
5	Standar deviasi (%)	2.64	2.38

No	Evaluasi	Nilai (%)	Nilai oh (%)
1	Akurasi	80.15	79.39
2	Presisi	73.91	73.33
3	Recall	70.83	68.75
4	F1	72.34	70.97
5	Mean absolute error	19.85	20.61
6	Root mean square error	44.55	45.39

•Nilai f1 yang dihasilkan dibawah nilai akurasi dari model

•Perbedaan nilai presisi dan recall sebesar 4.58%. Model yang baik memiliki nilai presisi semaksimal mungkin dan recall seminimum mungkin.

•Perbedaan antara perhitungan model tanpa over sampling meninjukan ketiga nilai yang mengalami peningkatan.

•Besarnya nilai f1, presisi dan recall ini bisa didapatkan dengan meninjau tabel confusion matrix.

•Model dapat memprediksi kemungkinan penumpang selamat atau tidak dengan tikat kesalahan 20.61%.

•Kualitas dari model memprediksi kemungkinan penumpang bertahan hidup atau tidak sebesar 45.39%.

	TP	TN		TP.os	TN.os
FP	71	12	FP.os	71	12
FN	14	34	FN.os	15	33

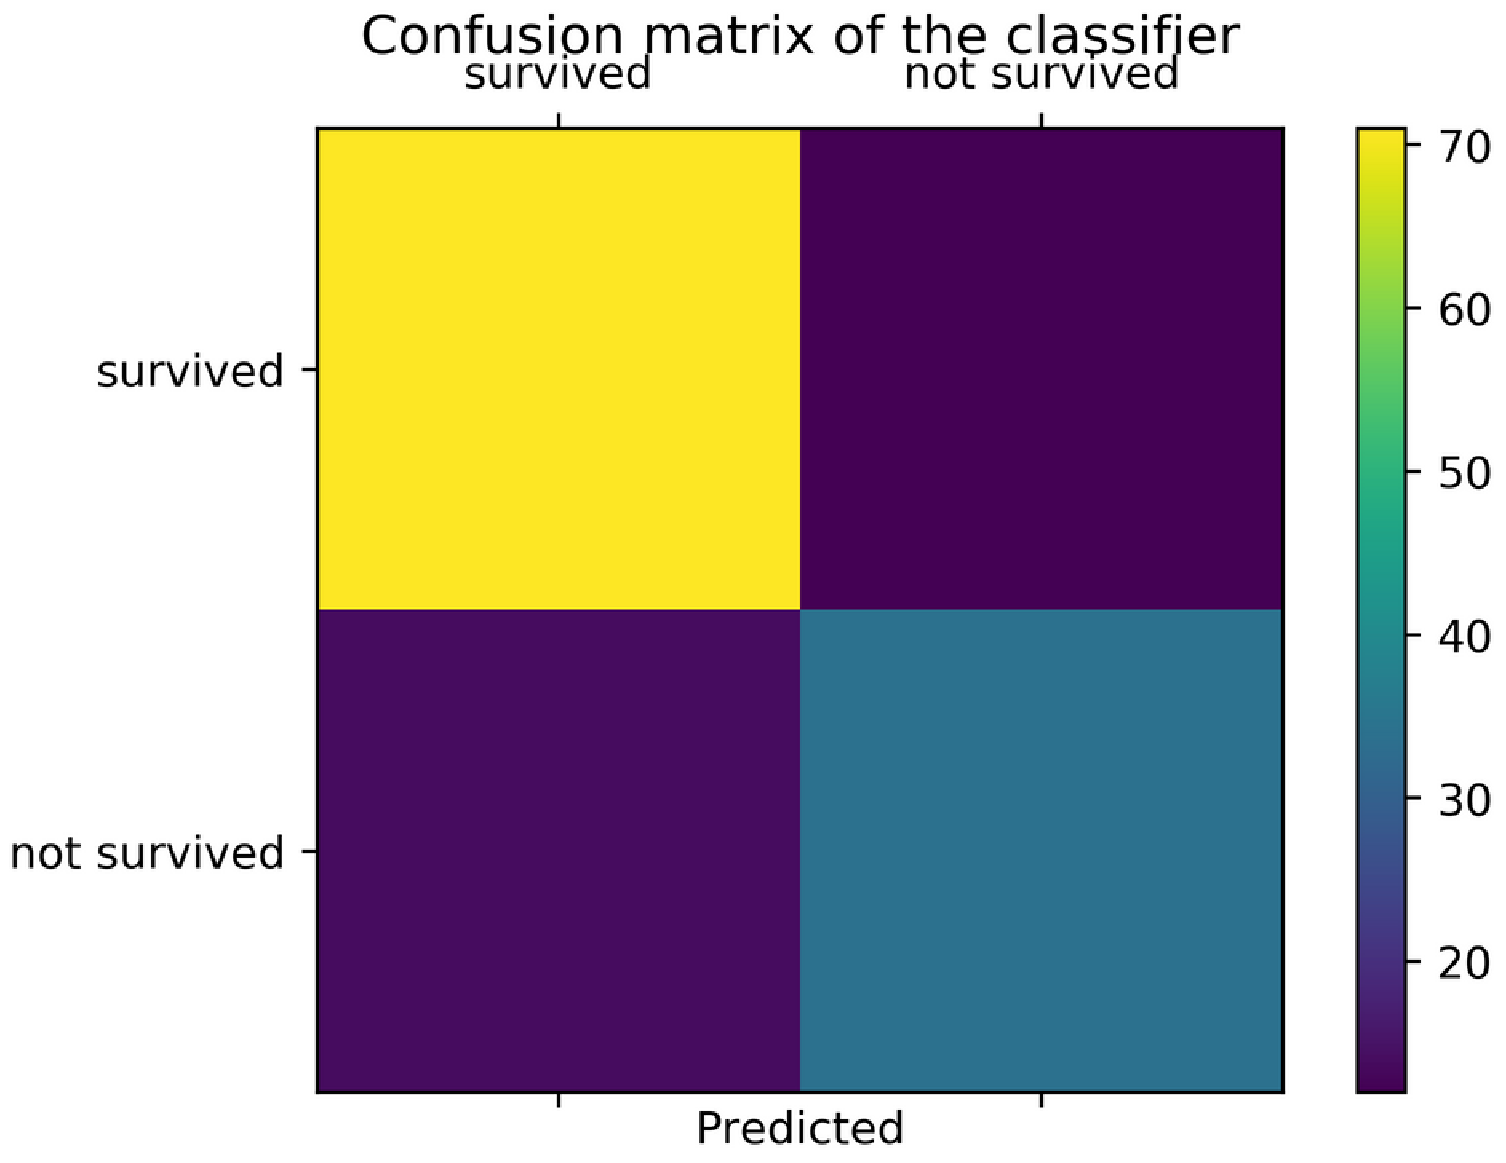

SUMMARY

HIGH CORRELATED ATTRIBUTE

Sex, Age, pClass, Honor/Title

SOCIAL PRIORITY

Saving Priority on Female, Children, and High Status

CANNOT EXCEED 82% ACCURACY

Luck factor on Disaster

Unique Person Attitude

SUGGESTION

MORE FEATURE ENGINEERING

Home destination

embarked

cabin

REFERENCES

Barkworth Family. https://www.encyclopedia-titanica.org/titanic-survivor/algernon-barkworth.html. Diakses pada tanggal 15 Agustus 2019 07:32 WIB.

Donges, N. 2018. Predicting the Survival of Titanic Passengers. https://towardsdatascience.com/predicting-the-survival-of-titanic-passengers-30870ccc7e8. Diakses pada tanggal 3 Agustus 2019 15:36 WIB.

Frey, B. S., et al. 2010. Interaction of natural survival instincts and internalized social norms exploring the Titanic and Lusitania disasters. Proc Natl Acad Sci. USA.

Kakde, Y. et al. 2018. Predicting Survival on Titanic by Applying Exploratory Data Analytics and Machine Learning Techniques. International journal of Computer Applications.

Lam, E, et al. 2012. CS229 Titanic – Machine Learning From Disaster.

Patil, P. 2018. What is Exploratory Data Analysis?. Towards Data Science.

Sherlock, J., et al. 2014 Classification of Titanic Passenger Data and Chances of Surviving the Disaster. Proceedings of Student-Faculty Research Day, CSIS, Pace University.

Singh, A., et al. 2017. Analyzing Titanic Disaster using Machine Learning Algorithms. International Conference on Computing, Communication and Automation.

Statistics Canada. 2017. Age Categories, Life Cycle Grouping. https://www.statcan.gc.ca/eng/concepts/definitions/age2. Diakses pada tanggal 14 Agustus 2019 05:23 WIB.